

Diffusion-TS 笔记

1. INTRODUCTION

1.1 时间序列生成的研究价值

时间序列数据在金融、医疗、气候、能源等领域应用广泛。但很多场景下，数据要么稀缺，要么涉及隐私无法直接共享。因此，合成和真实数据高度相似的时间序列，是解决这类问题的关键手段。

1.2 扩散模型的优势与现有方法痛点

1、扩散模型的优势：扩散概率模型（DDPM）是当下主流的生成模型，相比 GAN 等模型，它生成的样本质量更高，而且不存在对抗训练不稳定的问题，已经在图像、音频生成领域取得突破。

2、现有扩散类方法处理时间序列的 3 大痛点

- ①骨干网络有局限：大多用循环神经网络（RNN）做核心网络，但 RNN 存在误差积累问题——处理的序列越长，前面的小误差会不断叠加，最后生成的长序列和真实规律严重偏离。
- ②时序核心规律易丢失：真实时间序列包含趋势、周期等关键规律，但扩散模型的正向过程是逐步加噪，这些规律会被噪音破坏。现有方法没有专门的设计来保留和还原这些规律。
- ③可解释性与通用性差：生成的序列只能看“像不像”，说不清楚“为什么像”，是典型的“黑箱”结果；同时一个模型只能做一种任务，想换填补、预测任务就得重新改结构、训模型。

1.3 Diffusion-TS 的核心思路与贡献

1、核心思路：给扩散模型加入可解释的时序分解结构和傅里叶损失函数，让模型既能生成高质量样本，又能拆分出趋势、周期等成分；同时设计一种“重建引导”的采样策略，实现一个模型适配多类任务。

2、核心贡献：

- ① 提出融合时序分解技术与扩散模型的新框架，实现高可解释性的通用时间序列生成。

- ②设计实例感知的引导策略，让模型无需修改结构，就能即插即用完成填补、预测等条件生成任务。
- ③通过大量实验验证，模型在无条件生成、条件生成等任务上，均优于当时的主流方法。

2. PROBLEM STATEMENT

2.1 基础符号定义

时间序列：用 $X_{1:\tau} = (x_1, \dots, x_\tau) \in \mathbb{R}^{\tau \times d}$ 表示，其中 τ 是时间步的数量（比如一个序列有 24 个时间点， $\tau = 24$ ）， d 是数据的维度（比如股票数据包含开盘价、收盘价等 6 个特征， $d = 6$ ）。

数据集：用 $DA = X_{1:\tau, i=1}^i$ 表示，包含 N 个独立的时间序列样本。

2.2 时间序列分解公式

论文的核心前提是：任何时间序列都能拆成 3 个可解释的独立成分，公式如下：

$$x_j = \zeta_j + \sum_{i=1}^m s_{i,j} + e_j, j = 0, 1, \dots, \tau - 1$$

公式理解：任意一个时间点的数据 = 趋势值 + 周期波动值 + 随机波动值，这三个部分叠加起来，就是我们看到的完整时间序列。

2.3 论文要解决的两个核心任务

- 无条件生成任务：让模型把随机的高斯噪声向量 Z_i ，转换成和真实数据集 DA 分布高度相似的合成时间序列 $\hat{X}_{1:\tau}^i$ 。简单说就是“凭空造出和真数据很像的假数据”。
- 条件生成任务：给定一个控制变量 y （比如填补任务里的已观测数据、预测任务里的历史数据），让模型生成符合这个条件的序列。简单说就是“根据已知数据，补全或预测未知数据”。

3. DIFFUSION-TS: INTERPRETABLE DIFFUSION FOR TIME SERIES

3.1 扩散框架 (DIFFUSION FRAMEWORK)

扩散框架是 Diffusion-TS 模型的底层生成范式，本质为基于概率建模的“正向加噪-反向去噪”双向过程，为后续所有技术创新提供基础生成逻辑与优化载体。该框架为后续模块提供了“加噪 - 去噪”的核心流程，是模型生成能力的基础。

1、正向过程：给数据加噪音。

$$\text{公式: } q(x_t|x_{t-1}) = N(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I)$$

公式理解：每一步加噪时，先把上一步的序列 x_{t-1} 乘以 $\sqrt{1 - \beta_t}$ 作为新的均值，再加上一个强度为 β_t 的高斯噪音，就得到了当前步的序列 x_t 。重复这个过程 T 次后，原本有规律的时间序列 x_0 ，会变成完全随机的高斯噪声 x_T 。

2、反向过程：让模型去噪音

$$\text{公式: } p_\theta(x_{t-1}|x_t) = N(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

公式理解：模型的目标，就是学习这个反向去噪的均值 $\mu_\theta(x_t, t)$ 。从纯噪声 x_T 出发，每一步都用这个均值指导去噪，重复 T 次后，就能生成和真实序列 x_0 相似的新序列。

3.2 分解模型架构 (DECOMPOSITION MODEL ARCHITECTURE)

分解模型架构是 Diffusion-TS 实现可解释性与长序列适配能力的核心组件，基于 Transformer 编码器 - 解码器结构设计，嵌入于 3.1 节扩散框架的反向去噪流程中，实现时序成分的解耦与精准学习。

1、编码器：输入带噪的时间序列，用 Transformer 的自注意力机制，捕捉序列的全局依赖关系（比如长序列的整体趋势），为解码器提供全局信息。

2、解码器：每个解码器块包含 3 个关键部分，专门学习不同的时序成分

Transformer 块：融合编码器的全局信息，捕捉序列的局部依赖关系。

趋势合成层：用多项式回归的方式，专门学习缓慢变化的趋势成分 ζ_j 。

傅里叶合成层：通过傅里叶变换，专门学习有周期规律的季节成分 $s_{i,j}$ 。

3、公式：

$$\hat{x}_0(x_t, t; \theta) = V_{tr}^t + \sum_{i=1}^D S_{i,t} + R$$

公式理解：模型不会直接生成完整序列，而是先分别算出趋势、多个周期波动、随机误差这三部分，再把它们加起来，得到最终的合成序列。这样我们就能清晰看到，生成的序列里哪些是趋势、哪些是周期规律。

3.3 傅里叶损失函数 (FOURIER-BASED TRAINING OBJECTIVE)

傅里叶损失函数是优化生成序列质量、强化周期特征捕捉能力的核心训练准则，替代传统扩散模型的噪声预测损失，通过时域 - 频域双维度约束提升模型性能。

1、传统损失的问题：传统扩散模型学的是“预测每一步加了多少噪音”，容易忽略时间序列的周期规律，导致生成的序列只有数值接近，但无周期性。

2、Diffusion-TS 的损失函数公式：

$$\mathcal{L}_\theta = \mathbb{E}_{t, x_0} \left[w_t \left[\lambda_1 |x_0 - \hat{x}_0(x_t, t, \theta)|^2 + \lambda_2 |\mathcal{FT}(x_0) - \mathcal{FT}(\hat{x}_0(x_t, t, \theta))|^2 \right] \right]$$

公式理解：这个损失函数包含两个部分：

λ_1 部分：直接比对真实序列 x_0 和模型生成序列 $\hat{x}_0$ 的数值误差，确保生成的序列在数值上和真实序列接近。

λ_2 部分：比对真实序列和生成序列的傅里叶变换结果，确保生成的序列和真实序列有一模一样的周期规律（比如都是每天一次的周期波动）。

3.4 时间序列的条件生成（CONDITIONAL GENERATION FOR TIME SERIES APPLICATIONS）

条件生成模块是实现模型多任务适配能力的关键，通过在反向扩散采样阶段引入梯度引导机制，无需修改模型核心结构，即可适配无条件生成、缺失值填补、未来值预测等多类任务。

该模块的核心是基于梯度的生成引导策略，在反向去噪的每一步采样过程中，以已知条件数据（缺失值填补任务中的已观测值、预测任务中的历史值）为约束，计算生成序列与条件数据的误差梯度，通过梯度反向传播调整生成方向。引入引导强度系数 η 与流畅性平衡系数 γ ，在满足条件约束的同时，保证生成序列的时序连续性与分布合理性。

公式：

$$\tilde{x}_0(x_t, t, \theta) = \hat{x}_0(x_t, t, \theta) + \eta \nabla_{x_t} \left(|x_a - \hat{x}_a(x_t, t, \theta)|_2^2 + \gamma \log p(x_{t-1}|x_t) \right)$$

公式理解：模型原本会生成一个基础序列 $\hat{x}_0$ ，现在我们根据已知的条件数据 x_a ，计算一个“引导梯度”——这个梯度会告诉模型“怎么调整，才能让生成的条件部分 $\hat{x}_a$ 更接近真实的 x_a ”。把这个梯度加到基础序列上，就得到了符合条件的最终序列 $\tilde{x}_0$ 。

缺失值填补任务：把已知的观测数据设为 x_a ，梯度会引导模型生成的缺失部分和已知部分无缝衔接。

未来值预测任务：把历史数据设为 x_a ，梯度会引导模型生成的未来部分和历史趋势保持一致。

4. EMPIRICAL EVALUATION

4.1 实验设置

- 1、数据集：用了 6 类不同的数据集，包括 4 个真实数据集（股票、电力、能源、fMRI）和 2 个模拟数据集（正弦信号、物理模拟），覆盖不同维度、不同长度的时间序列，确保实验结果有说服力。
- 2、对比模型：选择了 TimeGAN、TimeVAE、Diffwave 等主流时间序列生成模型，以及 CSDI 等专门做填补/预测的模型。
- 3、评估指标：用 4 个核心指标衡量效果

4.2 可解释性实验

- 1、实验方法：给模型输入加了 50 步噪音的序列，让模型还原并拆分出趋势、季节、误差成分。
- 2、实验结果：模型拆分出的趋势曲线和真实趋势几乎一致，季节成分准确捕捉了周期规律，误差成分接近随机波动；最终还原的序列和真实序列高度吻合。
- 3、结论：模型不仅能生成高质量序列，还能清晰解释序列的组成规律，可解释性拉满。

4.3 无条件生成实验

- 1、实验方法：让 Diffusion-TS 和所有对比模型，生成不同长度（24/64/128/256）的时间序列，用 4 个评估指标打分。
- 2、实验结果：

Diffusion-TS 在所有 6 个数据集的 4 个指标上，数值都显著低于对比模型，生成质量最优。

当序列长度增加到 256 时，其他模型的指标数值暴涨（效果暴跌），而 Diffusion-TS 的数值变化很小，长序列生成能力远超其他模型。
- 3、结论：Diffusion-TS 的无条件生成能力，在短序列和长序列场景下，均为当时最优。

4.4 条件生成实验

- 1、缺失值填补实验：设置 75%、90% 等高缺失率，对比 Diffusion-TS 和 CSDI 等专门填补模型的填补误差。

结果：Diffusion-TS 的填补误差远低于对比模型，尤其是 90% 缺失率的极端场景下，优势更明显。
- 2、未来值预测实验：在电力、能源数据集上，对比预测误差。

结果：Diffusion-TS 生成的未来序列和真实序列趋势一致，预测误差显著低于其他模型。

3、结论：Diffusion-TS 的条件生成能力，优于专门的填补/预测模型。

4.5 冷启动与不规则设置实验

1、实验设置：只用 10% 的干净数据训练模型，再用模型补全剩余 90% 的不规则数据（含大量缺失值），之后用补全的数据继续训练模型。

2、实验结果：即使只有 10% 的训练数据，Diffusion-TS 的效果依然远超其他模型；补全后的数据还能进一步提升模型性能，最终效果接近全量数据训练的水平。

3、结论：模型在数据稀缺、数据不规则的场景下，依然能稳定发挥。

4.6 消融实验

1、实验方法：依次去掉模型的某个核心模块（比如去掉傅里叶损失、去掉分解架构、去掉 Transformer），观察模型效果变化。

3、实验结果：

去掉傅里叶损失：模型捕捉周期规律的能力下降，生成序列的周期和真实序列偏差变大。

去掉分解架构：模型失去可解释性，生成质量也明显降低。

去掉 Transformer：模型捕捉长序列依赖的能力暴跌，长序列生成效果极差。

3、结论：模型的每个核心模块都是必要的，它们共同支撑了最终的最优效果。

5. CONCLUSIONS

5.1 核心结论

Diffusion-TS 通过时序分解架构和傅里叶损失函数，成功实现了高质量、可解释的时间序列生成；通过重建引导的采样策略，实现了“一次训练，多任务通用”的目标；大量实验证明，模型在无条件生成、条件生成、数据稀缺等场景下，均优于现有方法。

5.2 局限性

扩散模型的固有问题——推理成本较高。生成一个样本需要经过 T 步去噪，相比 GAN 等模型，生成速度更慢，对计算资源的要求更高。

6. 创新点总结

6.1 时序成分解耦架构

针对现有扩散模型生成结果无法拆分时序规律、可解释性差的痛点，设计专属时序分解架构，将时间序列的“趋势 - 周期 - 误差”成分明确解耦。

1、核心设计：基于“任意时间序列可拆分为趋势、季节、误差成分”的前提（公式： $x_j = \zeta_j + \sum_{i=1}^m s_{i,j} + e_j$ ），在 Transformer 解码器中嵌入三大专属模块——趋势合成层、傅里叶合成层、误差捕捉模块，分别学习三类成分后叠加输出完整序列。

2、创新点：打破传统扩散模型“生成即终点”的模式，不仅能生成高质量序列，还能清晰输出各时序成分，让用户明确“生成序列的趋势的是上涨 / 下降、周期是日度 / 周度”；同时分解架构降低了长序列依赖学习难度，缓解长序列生成误差积累问题。

6.2 傅里叶损失函数

摒弃传统扩散模型“预测噪音”的损失设计，提出融合时间域与频率域的双损失函数，精准捕捉时序周期规律。

1、核心设计：损失函数公式为 $\mathcal{L}_\theta = \mathbb{E}_{t, x_0} \left[w_t \left[\lambda_1 |x_0 - \hat{x}_0(x_t, t, \theta)|^2 + \lambda_2 |\mathcal{FT}(x_0) - \mathcal{FT}(\hat{x}_0(x_t, t, \theta))|^2 \right] \right]$ ，包含两大损失项：

时间域损失（ λ_1 项）：比对生成序列与真实序列的数值误差，保证“形似”；

频率域损失（ λ_2 项）：通过傅里叶变换比对两者频率特征，强制模型复刻真实序列的周期规律，保证“神似”；

同时引入权重 w_t ，让模型重点关注高噪音步骤的学习，提升去噪精度。

2、创新点：解决传统损失函数忽略时序周期的缺陷，生成序列既能在数值上贴近真实数据，又能精准还原周期波动规律，避免“数值对但周期错”的问题，尤其适配电力、能源等强周期时序场景。

6.3 重建引导的条件生成策略

设计实例感知的梯度引导策略，实现“一次训练、多任务适配”，无需修改模型结构即可兼容无条件生成、缺失值填补、未来预测三大任务。

1、核心设计：在反向去噪采样阶段嵌入梯度引导机制（公式： $\tilde{x}_0(x_t, t, \theta) = \hat{x}_0(x_t, t, \theta) + \eta \nabla_{x_t} \left(|x_a - \hat{x}_a(x_t, t, \theta)|_2^2 + \gamma \log p(x_{t-1}|x_t) \right)$ ），以已知条件数据 x_a 为约束，通过梯度调整生成方向，让生成序列贴合已知条件，同时平衡序列流畅性。

2、创新点：突破传统扩散模型“一模型一任务”的局限，无需重新设计结构或训练，仅通过调整条件数据即可切换任务；在高缺失率（90%）、数据稀缺（仅 10% 训练数

据) 场景下仍表现优异, 大幅提升模型的实用价值与场景适配能力。