

Time-o1: Time-Series Forecasting Needs Transformed Label Alignment

2025年Neurips

北京大学, 中国人民大学

项目开源地址: <https://github.com/Master-PLC/Time-o1>

主讲人: 王杨

2026/03/10

* 代表是我的表述 (对原文的复述或个人评论) 或我画的图, 并非原始文章内容

*研究概述:

提出了一种名为 Time-o1 的全新**损失函数**。它通过数学变换，**将原本相互关联的未来数据**（标签），**转换成一组互不相关且按重要性排序的独立目标**，让模型优先学习那些最重要的成分。该方法有效化解了传统损失函数（MSE）因"标签自相关"导致的错误重复惩罚问题，降低了模型平滑、保守的模糊预测倾向，使其能够还原剧烈波动，生成更加清晰的预测。作为一种即插即用的模块，在不增加模型复杂度的前提下，提升了长序列预测的精度。

*Method概述:

1. 特征分解:

- 利用奇异值分解（SVD）等数学工具，对真实的标签序列进行拆解。这一步旨在**从复杂的原始时序数据中，提取出相互独立、且严格按照信息重要性（方差大小）排序的核心基础成分**。

2. 空间转换:

- 将真实的标签序列与模型生成的预测序列，同步映射到上一步提取出的独立特征空间中。通过这种视角的转换，**彻底消除原始时间序列点与点之间的“自相关性”，让后续的误差计算不再受惯性干扰**。

3. 降维对齐: 舍弃掉包含大量随机噪声的次要成分，**强制模型仅对保留下来的、最重要的核心主成分进行独立误差计算（L1 Loss）与对齐，降低了模型的学习难度**。

1. Intro & Motivation

Intro梳理:

1. 指出当前时序研究的现状：当前时间序列研究大多把精力放在模型架构的优化上，几乎所有模型都在使用MSE作为默认的损失函数。
2. 总结了MSE作为时间序列损失函数的两大问题：
 1. 忽略了“标签自相关性”
 2. 包含了过多的优化任务

1. Intro & Motivation

1.1 MSE局限性（一）——标签自相关性：

一、为什么时间序列的标签自相关性会让使用MSE作为损失函数出现问题？

*神经网络训练的本质，是**让模型给出的预测分布，尽可能地逼近真实世界中数据的概率分布**。也就是，要找到一组模型参数，使得在给定模型预测值 $\hat{y}$ 的情况下，真实标签 y 出现的概率最大。

理论上，真实标签序列的负对数似然，也就是理论上**最完美的损失函数**是这样的：

$$\text{Perfect Loss} = (y - \hat{y})^T \Sigma^{-1} (y - \hat{y})$$

其中， Σ 是标签序列的**协方差矩阵**，表示标签间的相关关系。

当我们使用MSE作为损失函数时，其计算方式是把每一时刻的预测误差单独平方，然后再加起来：

$$\text{MSE Loss} = (y_1 - \hat{y}_1)^2 + (y_2 - \hat{y}_2)^2 + \dots + (y_t - \hat{y}_t)^2$$

$$\text{MSE Loss} = (y - \hat{y})^T (y - \hat{y})$$

MSE的计算方式无视了标签间的相关性。也就是说，**MSE的隐藏假设是：时间序列的各个时点间不存在相关关系。**

因此，只要序列存在相关性，在MSE指导下训练出来的模型就一定偏离了数据的真实分布。

1. Intro & Motivation

1.1 MSE局限性（一）——标签自相关性：

* 二、这种偏差反应到模型预测效果上意味着什么？


假设模型要预测晚18:00 到 22:00 的城市用电负荷。真实规律下，每天晚上19:30到20:30会出现一个极其陡峭的用电晚高峰。

预测 A（结构准确，相位偏移）：精准捕捉了波峰的幅度和形状，但在发生的时间点上存在轻微偏差（15分钟）。

预测 B（纯直线）：未捕捉任何波动和趋势的水平直线。

性能良好的损失函数给A的惩罚应该低于B，但在MSE下，模型给出一个未捕捉任何趋势和波动的水平直线反而得到了更小的惩罚。

这就是忽略自相关性所导致的概率分布偏差。模型学到的不再是数据真实的剧烈波动分布，而是为了迎合 MSE 而妥协出的一种平滑、保守的伪分布。



1. Intro & Motivation

1.2 MSE局限性（二）——过多的优化任务：

在时间序列预测中，如果使用MSE作为损失函数，由于其将每个时点的预测视为独立任务，因此也就相当于给模型布置了T个并行的微小任务，这样的多任务学习很容易导致模型优化困难。

*比如，预测近端点，比如 $t=1$ ，往往需要模型提取局部的短程依赖特征；而预测远端点，比如 $t=720$ 则需要模型捕捉低频、全局周期性特征。当模型同时受到由 $t=1$ 和 $t=720$ 反向传来的梯度时，这两个梯度的方向往往是存在冲突的，导致模型参数更新困难。

1.3 Motivation总结：

由于MSE 的“逐点对齐”机制与时间序列固有的标签自相关性相冲突，容易造成错误重复惩罚；且长序列预测产生过多的微小优化任务，导致梯度冲突与拟合困难。

作者提出，时间序列预测的loss应该：

- (1) 消除未来预测步骤之间的相关性；
- (2) 摒弃冗余噪音，仅对最具信息量的核心特征进行优化


How?

2. Method

2.1 Time-o1 loss计算的整体流程

作者提出，将时间序列的标签序列转换到一个能够去除标签间相关性并且能够区分特征重要性的**隐空间**，在这个隐空间中计算 loss。

假设我们现在已经得到了这样一个隐空间的映射矩阵 P ，time-o1 loss 的计算流程如下：



How?

2. Method

2.2 矩阵P的获取

2.2.1 具体优化任务

为了找到那个完美的变换矩阵 P (即包含一组基向量 $p_1, p_2, \dots, p_K$) , 我们需要让它满足我们最初设定的目标: 提取核心特征且消除自相关性。为此, 我们构建了如下的优化任务:

$$p_k^* = \operatorname{argmax}_{p_k} (Y p_k)^T (Y p_k)$$

$$\text{subject to } \begin{cases} \|p_k\|^2 = 1 \\ p_k^T p_{k'} = 0, \forall k' < k \quad \text{if } k > 1 \end{cases}$$

1. 核心优化目标: 最大化方差

- *隐含假设: 这里作者假设方差越大, 序列蕴含的信息量就越大。
- 由于是逐个寻找这些基向量的, 这个优化目标天然保证了找出来的隐空间表征, 是严格按照信息量从大到小排好序了的。从而后续可以简单通过“截断”操作保留最前面的核心成分。

2. 约束条件一: 长度为1

- 这个约束条件是为了得到有意义的唯一解, 否则算法可以通过无限放大向量 p_k 的数值来作弊

3. 约束条件二: 内积为0

- 这个约束条件是正交约束, 强制要求当前寻找的第 k 个向量必须与前面找出的所有向量完全垂直;
- 正交也就意味着互不相关。

2. Method

2.2 矩阵P的获取

2.2.2 优化任务的解——SVD

$$p_k^* = \underset{p_k}{\operatorname{argmax}} (Y p_k)^T (Y p_k)$$
$$\text{subject to } \begin{cases} ||p_k||^2 = 1 \\ p_k^T p_{k'} = 0, \forall k' < k \quad \text{if } k > 1 \end{cases}$$

P^* 可以通过矩阵的奇异值分解, Singular Value Decomposition (SVD)来简单获取!

SVD的详细讲解视频链接:

<https://www.youtube.com/watch?v=vSczTbgc8Rc&t=72s>

2. Method

2.2 矩阵P的获取

*2.2.2 优化任务的解——SVD

简单来说，SVD是一种矩阵分解算法，能够将任意大小的矩阵分解为3个矩阵相乘：

$$Y = U\Sigma V^T,$$

其中， U 是一个正交矩阵， Σ 是一个与 Y 有相同维度的对角矩阵， V 是一个正交矩阵。具体来讲，假设 Y 的维度为 $N * T$

U ：将 $S_L = YY^T$ 矩阵的奇异向量按降序排列得到的矩阵， U 的维度为 $N * N$ ；

Σ ：将 Y 的奇异值按降序排列在矩阵的对角线上，其余元素用0填充的矩阵， Σ 的维度为 $T * T$ ；

V ：将 $S_L = Y^TY$ 矩阵的奇异向量按降序排列得到的矩阵， V 的维度为 $T * T$ ；

$$\begin{matrix} Y \\ N \times T \end{matrix} = \begin{matrix} \begin{bmatrix} \vec{u}_{1L} & \vec{u}_{2L} & \dots & \vec{u}_{nL} \\ | & | & & | \end{bmatrix} \\ N \times N \end{matrix} \times \begin{matrix} \begin{bmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_T \end{bmatrix} \\ N \times T \end{matrix} \times \begin{matrix} \begin{bmatrix} -\vec{u}_{1R} \\ -\vec{u}_{2R} \\ \vdots \\ -\vec{u}_{TR} \end{bmatrix} \\ T \times T \end{matrix}$$

$\vec{u}_{1L}, \vec{u}_{2L}, \dots, \vec{u}_{nL}$ ： YY^T 归一化后的奇异变量（从大到小排序）

$\sigma_1, \sigma_2, \dots, \sigma_T$ ： Y 的奇异值（从大到小排序）

$\vec{u}_{1R}, \vec{u}_{2R}, \dots, \vec{u}_{nR}$ ： Y^TY 归一化后的奇异变量（从大到小排序）

2. Method

2.2 矩阵P的获取

*2.2.2 优化任务的解——SVD

简单来说，SVD是一种矩阵分解算法，能够将任意大小的矩阵分解为3个矩阵相乘：

$$Y = U \Sigma V^T,$$

其中， U 是一个正交矩阵， Σ 是一个与 Y 有相同维度的对角矩阵， V 是一个正交矩阵。具体来讲，假设 Y 的维度为 $N * T$

U ：将 $S_L = YY^T$ 矩阵的奇异向量按降序排列得到的矩阵， U 的维度为 $N * N$ ；

Σ ：将 Y 的奇异值按降序排列在矩阵的对角线上，其余元素用0填充的矩阵， Σ 的维度为 $T * T$ ；

V ：将 $S_L = Y^TY$ 矩阵的奇异向量按降序排列得到的矩阵， V 的维度为 $T * T$ ；

$$\begin{matrix} Y \\ N \times T \end{matrix} = \begin{matrix} \begin{bmatrix} \vec{u}_{1L} & \vec{u}_{2L} & \dots & \vec{u}_{nL} \\ | & | & & | \end{bmatrix} \\ N \times N \end{matrix} \times \begin{matrix} \begin{bmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_T \end{bmatrix} \\ N \times T \end{matrix} \times \begin{matrix} \begin{bmatrix} -\vec{u}_{1R} \\ -\vec{u}_{2R} \\ \vdots \\ -\vec{u}_{TR} \end{bmatrix} \\ T \times T \end{matrix}$$

V 就是满足我们条件的 P^*

$\vec{u}_{1L}, \vec{u}_{2L}, \dots, \vec{u}_{nL}$ ： YY^T 归一化后的奇异变量（从大到小排序）

$\sigma_1, \sigma_2, \dots, \sigma_T$ ： Y 的奇异值（从大到小排序）

$\vec{u}_{1R}, \vec{u}_{2R}, \dots, \vec{u}_{nR}$ ： Y^TY 归一化后的奇异变量（从大到小排序）

2. Method



2.2 矩阵P的获取

*2.2.3 V的有效性数学证明

当令 $P^* = V$ 时, $Z = Y P^* = U \Sigma V^T V$

$\because V$ 为正交矩阵 $\therefore V^T V = I, Z = U \Sigma$

根据要求, Z 要满足两点条件: ① $z_1, z_2, \dots, z_T$ 之间彼此无交
② $z_1, z_2, \dots, z_T$ 按方差从大到小排序

验证第一点: $Z^T Z = (U \Sigma)^T (U \Sigma)$
 $= \Sigma^T U^T U \Sigma \quad (U: \text{正交矩阵} \therefore U^T U = I)$
 $= \Sigma^T \Sigma$
 $\because \Sigma$ 为对角矩阵 $\therefore \Sigma^T \Sigma = \Sigma^2$

$$\therefore Z^T Z = \begin{bmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_1^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_T^2 \end{bmatrix}_{T \times T}$$

得证

验证第二点: 从 (1) 的证明可得, $Z^T Z = \Sigma^2 = \begin{bmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_1^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_T^2 \end{bmatrix}_{T \times T}$

$$\therefore z_i^T z_i = \sigma_i^2$$

$\because z_i$ 的方差 $= z_i^T z_i$, 也就是自己的内积

且我们根据SVD的定义可知, $\sigma_1, \dots, \sigma_T$ 是按值的大小从大到小排列的

$$\therefore \text{可得, 对 } i > j, z_i^T z_i < z_j^T z_j$$

得证

2. Method

2.2 矩阵P的获取

*2.2.4 V的有效性实例证明

```
# —— 4. 损失计算 ——
```

```
# 传统 MSE
```

```
mse_a = np.mean((y_true_norm - y_model_a_norm)**2)  
mse_b = np.mean((y_true_norm - y_model_b_norm)**2)
```

```
# Time-ol Loss (在此设定 K=1, 即保留 K=1 主成分)
```

```
P_k = P_star[:, :K]
```


```
z_true = y_true_norm @ P_k  
z_a = y_model_a_norm @ P_k  
z_b = y_model_b_norm @ P_k
```

```
time_ol_loss_a = np.sum(np.abs(z_true - z_a)) / K
```

```
time_ol_loss_b = np.sum(np.abs(z_true - z_b)) / K
```

```
# —— 1. 场景与真实数据 (纯净、无噪音) ——  
T = 200  
hours = np.linspace(18, 22, T)  
  
def gen_peak(center, width, height):  
    """生成一个纯净的波峰函数"""  
    return height * np.exp(-(hours - center)**2 / width)  
  
# 真实标签: 20:00 准时爆发的陡峭晚高峰
```

MSE A (形状完美, 错位15分钟): 2.0
MSE B (未捕捉任何趋势的直线): 1.0
Time-ol Loss A (保留 K=1 主成分): 3.7
Time-ol Loss B (保留 K=1 主成分): 9.9



```
# SVD 提取空间变换矩阵 P*
```

```
U, S, Vh = np.linalg.svd(Y_dataset, full_matrices=False)
```

```
P_star = Vh.T
```

```
_true)
```

发情况晚了 15 分钟 (20:15)

```
(np.std(y_model_a)
```

比如在19:30到20:30之间随机)

天然存在的相位方差

2. Method


2.2 矩阵P的获取

2.2.5 为什么不直接用傅里叶变换+topk在频域上计算loss


1. 在严格的数学推导中，傅里叶变换后各个频率成分完全不相关的前提条件是：这个时间序列是无限长的。

因此，在实际的预测中，当我们对一段有限长的数据做傅里叶变换，会发生频谱泄露和边界效应，导致提取出的成分之间仍然存在相关性。

使用傅里叶变换后得到的成分间的相关性



使用P*变换后得到的成分间的相关性



蓝色图源作者的前一篇文章：

Fredf: Learning to forecast in the frequency domain

这篇文章就是在频域空间内计算的loss

2. Method

2.3 模型具体训练流程

1. 归一化
2. 确定隐空间的向量保留比例
3. 根据当前数据集的全部Y计算出一个统一的 P^*
4. 将Y和预测值 $\hat{Y}$ 同时与 P^* 相乘得到Z, $\hat{Z}$
5. 计算 $\hat{Z}$ 和Z的L1 loss
6. 计算标准MSE loss
7. 将两个loss按一定比例混合

Algorithm 1 The workflow of Time-o1.

Input: $\hat{Y}$: forecast sequences, Y : label sequences.

Parameter: α : the relative weight of the transformed loss, γ : the ratio of retained components.

Output: $\mathcal{L}_{\alpha, \gamma}$: the obtained loss function.

- 1: $Y \leftarrow \text{standardize}(Y)$.
 - 2: $K \leftarrow \text{round}(\gamma \cdot T)$
 - 3: $P^* \leftarrow \text{SVD}(Y; K)$
 - 4: $Z \leftarrow YP^*, \hat{Z} \leftarrow \hat{Y}P^*$
 - 5: $\mathcal{L}_{\text{ortho}, \gamma} \leftarrow \|\hat{Z} - Z\|_1$
 - 6: $\mathcal{L}_{\text{MSE}} \leftarrow \|\hat{Y} - Y\|_2^2$
 - 7: $\mathcal{L}_{\alpha, \gamma} := \alpha \cdot \mathcal{L}_{\text{ortho}, \gamma} + (1 - \alpha) \cdot \mathcal{L}_{\text{MSE}}.$
-

3. Experiments

3.1 模型训练设置

1. 数据集：长时间序列预测用了ETT, ECL, Traffic, Weather, PEMS数据集；短时间序列预测用了M4。
2. Baseline：Transformer, Autoformer, FEDformer, iTransformer, Fredformer, DLinear, TiDE, FreTS, TimesNet, MICN
3. 实验设置：Time-o1用了Fredformer作为基座模型，将它的损失函数改为了time-o1

Table 1: Long-term forecasting performance.

Models	Time-o1 (Ours)		Fredformer (2024)		iTransformer (2024)		FreTS (2023)		TimesNet (2023)		MICN (2023)		TiDE (2023)		DLinear (2023)		FEDformer (2022)		Autoformer (2021)		Transformer (2017)	
	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
ETTh1	0.380	0.393	<u>0.387</u>	<u>0.398</u>	0.411	0.414	0.414	0.421	0.438	0.430	0.396	0.421	0.413	0.407	0.403	0.407	0.442	0.457	0.526	0.491	0.799	0.648
ETTh2	0.272	0.317	<u>0.280</u>	<u>0.324</u>	0.295	0.336	0.316	0.365	0.302	0.334	0.308	0.364	0.286	0.328	0.342	0.392	0.308	0.354	0.315	0.358	1.662	0.917
ETTh1	0.431	0.429	<u>0.447</u>	<u>0.434</u>	0.452	0.448	0.489	0.474	0.472	0.463	0.533	0.519	0.448	0.435	0.456	0.453	0.447	0.470	0.477	0.483	0.983	0.774
ETTh2	0.359	0.388	<u>0.377</u>	0.402	0.386	0.407	0.524	0.496	0.409	0.420	0.620	0.546	0.378	<u>0.401</u>	0.529	0.499	0.452	0.461	0.448	0.460	2.688	1.291
ECL	0.170	0.260	0.191	0.284	<u>0.179</u>	<u>0.270</u>	0.199	0.288	0.212	0.306	0.192	0.302	0.215	0.292	0.212	0.301	0.214	0.328	0.249	0.354	0.265	0.358
Traffic	0.419	0.280	0.486	0.336	<u>0.426</u>	<u>0.285</u>	0.538	0.330	0.631	0.338	0.529	0.312	0.624	0.373	0.625	0.384	0.640	0.398	0.662	0.416	0.692	0.379
Weather	0.241	0.280	0.261	<u>0.282</u>	0.269	0.289	<u>0.249</u>	0.293	0.271	0.295	0.264	0.321	0.272	0.291	0.265	0.317	0.326	0.372	0.319	0.365	0.699	0.601
PEMS03	0.097	0.208	0.146	0.260	0.122	0.233	0.149	0.261	0.126	0.230	<u>0.106</u>	<u>0.223</u>	0.316	0.370	0.216	0.322	0.152	0.275	0.411	0.475	0.122	0.226
PEMS08	0.141	0.237	0.171	0.271	<u>0.149</u>	<u>0.247</u>	0.174	0.275	0.152	0.243	0.153	0.258	0.318	0.378	0.249	0.332	0.226	0.312	0.422	0.456	0.240	0.261

Note: We fix the input length as 96 following [28]. **Bold** and underlined denote best and second-best results, respectively. Avg indicates average results over forecast horizons: T=96, 192, 336 and 720. Time-o1 employs the top-performing baseline on each dataset as its underlying forecast model.

3. Experiments

3.2 主实验结果

用了time-o1作为损失函数的fredformer模型在mse评价指标上取得了最好的结果

Table 1: Long-term forecasting performance.

Models	Time-o1 (Ours)		Fredformer (2024)		iTransformer (2024)		FreTS (2023)		TimesNet (2023)		MICN (2023)		TiDE (2023)		DLinear (2023)		FEDformer (2022)		Autoformer (2021)		Transformer (2017)	
	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
ETTm1	0.380	0.393	<u>0.387</u>	<u>0.398</u>	0.411	0.414	0.414	0.421	0.438	0.430	0.396	0.421	0.413	0.407	0.403	0.407	0.442	0.457	0.526	0.491	0.799	0.648
ETTm2	0.272	0.317	<u>0.280</u>	<u>0.324</u>	0.295	0.336	0.316	0.365	0.302	0.334	0.308	0.364	0.286	0.328	0.342	0.392	0.308	0.354	0.315	0.358	1.662	0.917
ETTh1	0.431	0.429	<u>0.447</u>	<u>0.434</u>	0.452	0.448	0.489	0.474	0.472	0.463	0.533	0.519	0.448	0.435	0.456	0.453	0.447	0.470	0.477	0.483	0.983	0.774
ETTh2	0.359	0.388	<u>0.377</u>	0.402	0.386	0.407	0.524	0.496	0.409	0.420	0.620	0.546	0.378	<u>0.401</u>	0.529	0.499	0.452	0.461	0.448	0.460	2.688	1.291
ECL	0.170	0.260	0.191	0.284	<u>0.179</u>	<u>0.270</u>	0.199	0.288	0.212	0.306	0.192	0.302	0.215	0.292	0.212	0.301	0.214	0.328	0.249	0.354	0.265	0.358
Traffic	0.419	0.280	0.486	0.336	<u>0.426</u>	<u>0.285</u>	0.538	0.330	0.631	0.338	0.529	0.312	0.624	0.373	0.625	0.384	0.640	0.398	0.662	0.416	0.692	0.379
Weather	0.241	0.280	0.261	<u>0.282</u>	0.269	0.289	<u>0.249</u>	0.293	0.271	0.295	0.264	0.321	0.272	0.291	0.265	0.317	0.326	0.372	0.319	0.365	0.699	0.601
PEMS03	0.097	0.208	0.146	0.260	0.122	0.233	0.149	0.261	0.126	0.230	<u>0.106</u>	<u>0.223</u>	0.316	0.370	0.216	0.322	0.152	0.275	0.411	0.475	0.122	0.226
PEMS08	0.141	0.237	0.171	0.271	<u>0.149</u>	<u>0.247</u>	0.174	0.275	0.152	0.243	0.153	0.258	0.318	0.378	0.249	0.332	0.226	0.312	0.422	0.456	0.240	0.261

Note: We fix the input length as 96 following [28]. **Bold** and underlined denote best and second-best results, respectively. Avg indicates average results over forecast horizons: T=96, 192, 336 and 720. Time-o1 employs the top-performing baseline on each dataset as its underlying forecast model.

3. Experiments

3.3 对比实验结果

使用其他损失函数进行训练的fredformer模型在mse评价指标上不如使用time-o1作为损失函数的

Table 2: Comparable results with other loss functions for time-series forecast.

Loss		Time-o1		FreDF		Koopman		Dilate		Soft-DTW		DPTA		DF	
Metrics		MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
Fredformer	ETTm1	0.379	0.393	<u>0.384</u>	<u>0.394</u>	0.389	0.400	0.389	0.400	0.397	0.402	0.396	0.402	0.387	0.398
	ETTh1	0.431	0.429	<u>0.438</u>	<u>0.434</u>	0.452	0.443	0.453	0.442	0.460	0.449	0.460	0.449	0.447	0.434
	ECL	0.178	0.270	<u>0.179</u>	<u>0.272</u>	0.190	0.282	0.187	0.280	0.206	0.298	0.202	0.294	0.191	0.284
	Weather	0.255	0.276	<u>0.256</u>	<u>0.277</u>	0.257	0.279	0.258	0.280	0.261	0.280	0.260	0.280	0.261	0.282
iTransformer	ETTm1	0.395	0.401	<u>0.405</u>	<u>0.405</u>	0.413	0.416	0.407	0.412	0.417	0.415	0.416	0.415	0.411	0.414
	ETTh1	0.438	0.434	<u>0.442</u>	<u>0.437</u>	0.455	0.451	0.452	0.448	0.470	0.457	0.463	0.454	0.452	0.448
	ECL	0.170	0.260	0.176	<u>0.264</u>	0.178	0.269	0.178	0.269	<u>0.175</u>	0.266	0.177	0.267	0.179	0.270
	Weather	0.251	0.272	<u>0.257</u>	<u>0.276</u>	0.289	0.313	0.286	0.309	0.292	0.316	0.291	0.313	0.269	0.289

Note: **Bold** and underlined denote best and second-best results, respectively. The reported results are averaged over forecast horizons: T=96, 192, 336 and 720.

3. Experiments

3.3 消融实验结果

不论是去相关性还是去冗余优化目标，都对模型训练有帮助，但相较而言去相关性的作用更明显一些

Table 3: Ablation study results.

Model	Decorrelation	Reduction	Data	T=96		T=192		T=336		T=720		Avg	
				MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
DF	✗	✗	ETTm1	0.326	0.361	0.365	0.382	0.396	0.404	0.459	0.444	0.387	0.398
			ETTh1	0.377	0.396	0.437	0.425	0.486	0.449	0.488	0.467	0.447	0.434
			ECL	0.150	0.242	0.168	0.259	0.182	0.274	0.214	0.304	0.179	0.270
			Weather	0.174	0.228	0.213	0.266	0.270	0.316	0.337	0.362	0.249	0.293
Time-ol [†]	✗	✓	ETTm1	0.338	0.366	0.369	0.383	0.397	0.403	0.458	0.441	0.391	0.398
			ETTh1	0.376	0.395	0.437	0.430	0.478	0.450	<u>0.469</u>	0.467	0.440	0.436
			ECL	0.150	0.239	0.164	0.253	0.178	0.268	0.210	0.296	0.175	0.264
			Weather	<u>0.170</u>	0.216	0.213	0.259	0.262	<u>0.300</u>	0.332	<u>0.351</u>	0.244	<u>0.281</u>
Time-ol [‡]	✓	✗	ETTm1	<u>0.324</u>	<u>0.359</u>	<u>0.362</u>	<u>0.379</u>	<u>0.390</u>	<u>0.400</u>	<u>0.451</u>	<u>0.438</u>	<u>0.382</u>	<u>0.394</u>
			ETTh1	<u>0.373</u>	<u>0.395</u>	<u>0.433</u>	<u>0.423</u>	<u>0.476</u>	<u>0.445</u>	0.474	<u>0.463</u>	0.439	<u>0.431</u>
			ECL	<u>0.147</u>	<u>0.238</u>	<u>0.162</u>	<u>0.252</u>	<u>0.174</u>	<u>0.267</u>	<u>0.205</u>	<u>0.294</u>	<u>0.172</u>	<u>0.263</u>
			Weather	0.172	0.220	<u>0.211</u>	<u>0.259</u>	<u>0.261</u>	0.301	<u>0.331</u>	0.353	<u>0.244</u>	0.283
Time-ol	✓	✓	ETTm1	0.321	0.357	0.360	0.378	0.389	0.400	0.447	0.435	0.379	0.393
			ETTh1	0.368	0.391	0.424	0.422	0.467	0.441	0.465	0.463	0.431	0.429
			ECL	0.145	0.235	0.159	0.249	0.173	0.264	0.203	0.292	0.170	0.260
			Weather	0.169	<u>0.219</u>	0.210	0.258	0.259	0.297	0.327	0.349	0.241	0.280

Note: **Bold** and underlined denote best and second-best results, respectively.

3. Experiments

3.3 超参设置及对应敏感性实验

1. ETTh1 数据集 (ETTh1_PCA)

在这个数据集中，Time-o1 loss (辅助损失) 占据了绝对的主导地位 (权重均为 1.0)，而 MSE loss 的权重为 0。

- 预测长度 96: rank_ratio = 1.0, lambda = 0.0 (MSE 占比 0%, Time-o1 占比 100%)
- 预测长度 192: rank_ratio = 1.0, lambda = 0.0 (MSE 占比 0%, Time-o1 占比 100%)
- 预测长度 336: rank_ratio = 1.0, lambda = 0.0 (MSE 占比 0%, Time-o1 占比 100%)
- 预测长度 720: rank_ratio = 0.9, lambda = 0.0 (MSE 占比 0%, Time-o1 占比 100%)

3. ETTm1 数据集 (ETTm1_PCA)

ETTm1 数据集采用了动态的混合策略：随着预测长度的增加，MSE loss 的比重逐渐降低，而 Time-o1 loss 的比重逐渐增加 (甚至在 720 步时完全摒弃了 MSE)。

- 预测长度 96: rank_ratio = 1.0, lambda = 0.6 (MSE 占比 60%, Time-o1 占比 40%)
- 预测长度 192: rank_ratio = 1.0, lambda = 0.2 (MSE 占比 20%, Time-o1 占比 80%)
- 预测长度 336: rank_ratio = 0.7, lambda = 0.1 (MSE 占比 10%, Time-o1 占比 90%)
- 预测长度 720: rank_ratio = 0.8, lambda = 0.0 (MSE 占比 0%, Time-o1 占比 100%)

2. ETTh2 数据集 (ETTh2_PCA)

在这个数据集中，除预测长度为 336 时引入了 30% 的 MSE loss 混合外，其余长度同样完全依赖 Time-o1 loss。此外，对于不同的预测长度，截断比例有较明显的调整。

- 预测长度 96: rank_ratio = 1.0, lambda = 0.0 (MSE 占比 0%, Time-o1 占比 100%)
- 预测长度 192: rank_ratio = 0.6, lambda = 0.0 (MSE 占比 0%, Time-o1 占比 100%)
- 预测长度 336: rank_ratio = 0.8, lambda = 0.3 (MSE 占比 30%, Time-o1 占比 70%)
- 预测长度 720: rank_ratio = 1.0, lambda = 0.0 (MSE 占比 0%, Time-o1 占比 100%)

4. ETTm2 数据集 (ETTm2_PCA)

与 ETTh1 类似，该数据集下的实验也完全依赖 Time-o1 loss (辅助损失)，不混合 MSE，只是在 96 步和 720 步时对保留的成分比例做了一定截断。

- 预测长度 96: rank_ratio = 0.8, lambda = 0.0 (MSE 占比 0%, Time-o1 占比 100%)
- 预测长度 192: rank_ratio = 1.0, lambda = 0.0 (MSE 占比 0%, Time-o1 占比 100%)
- 预测长度 336: rank_ratio = 1.0, lambda = 0.0 (MSE 占比 0%, Time-o1 占比 100%)
- 预测长度 720: rank_ratio = 0.9, lambda = 0.0 (MSE 占比 0%, Time-o1 占比 100%)

3. Experiments

3.3 超参设置及对应敏感性实验

首先，使用time-o1 loss的比例越大，模型效果越好；第二，即使去相关性了，保留特征也不是越多越好，只保留70%的效果是最好的

Table 5: Hyperparameter results on α .

α	ETTm1		ETTh2		Weather	
	MSE	MAE	MSE	MAE	MSE	MAE
0	0.3867	0.3979	0.3766	0.4019	0.2486	0.2930
0.3	0.3871	0.3983	0.3742	0.3982	0.2439	0.2851
0.5	0.3864	0.3976	0.3703	0.3964	0.2432	0.2833
0.7	0.3831	<u>0.3959</u>	<u>0.3674</u>	0.3943	<u>0.2433</u>	<u>0.2849</u>
1	<u>0.3850</u>	0.3933	0.3606	<u>0.3890</u>	0.2753	0.3209

Note: **Bold** and underlined denote best and second-best results.

Table 6: Hyperparameter results on γ .

γ	ETTm1		ETTh2		Weather	
	MSE	MAE	MSE	MAE	MSE	MAE
0.1	0.3915	0.4002	0.3816	0.4029	<u>0.2437</u>	<u>0.2845</u>
0.3	0.3849	0.3964	0.3694	0.3961	0.2424	0.2825
0.5	0.3817	0.3943	0.3651	0.3923	0.2466	0.2877
0.7	0.3798	0.3930	0.3603	0.3886	0.2443	0.2861
1	<u>0.3814</u>	<u>0.3940</u>	<u>0.3624</u>	<u>0.3903</u>	0.2491	0.2924

Note: **Bold** and underlined denote best and second-best results.

The End